

Teoría estadística de campos p -ádicos y máquinas de Boltzmann convolucionales

David Felipe Angel Herrera Cristian Leonardo Castañeda Olarte

Departamento de Matemáticas
Universidad Nacional de Colombia

28 de julio de 2026

Contenido

- 1 Introducción
- 2 Marco Teórico
- 3 Metodología
- 4 Resultados
- 5 Discusión y conclusiones

- Redes densamente conectadas $\Rightarrow$ crecimiento cuadrático $O(N^2)$ de parámetros (ej. Máquinas de Boltzmann).
- Correspondencia reciente entre *Statistical Field Theories* (SFT) y redes neuronales.
- Idea central: la **geometría del espacio subyacente** condiciona la arquitectura neuronal.

Propuesta

Sustituir el espacio euclídeo por el cuerpo p -ádico $\mathbb{Q}_p$ para inducir una estructura jerárquica natural.

Objetivo del proyecto

- Implementar una versión simplificada de la arquitectura p -ádica.
- Explorar experimentalmente su capacidad de aprender representaciones jerárquicas.
- Comparar el número de parámetros frente a modelos convencionales.

Restricted Boltzmann Machines y Convolutional Deep Boltzmann Machines

Restricted Boltzmann Machines (RBM)

- Conexiones solo entre capa visible v y capa oculta h .
- Permite algoritmos eficientes (divergencia contrastiva).
- Persiste el problema: matriz de pesos densa $\Rightarrow O(N^2)$.

Convolutional Deep Boltzmann Machines (CDBM)

- Incorporan estructura convolucional: comparten parámetros entre regiones.
- Reducen el número de pesos frente a una DBM completamente conectada.
- Punto de partida que este trabajo extiende al caso p-ádico.

- $\mathbb{Q}_p$: espacio ultramétrico (desigualdad triangular fuerte).
- Los enteros p-ádicos se organizan en un **árbol jerárquico p-ario**.

Propiedades fundamentales

- **Jerarquía natural**: cercanía $\leftrightarrow$ ancestro común en el árbol.
- **Discretización**: truncar el árbol a profundidad l finita.

Árbol p-ádico




Figura: Árbol asociado a $\mathbb{Z}_2/2^3\mathbb{Z}_2$.
Imagen tomada de Zúñiga-Galindo (2023)

- ❶ **Convolución p-ádica:** núcleo que depende de la distancia en el árbol.
- ❷ **Compartición de parámetros:** neuronas equivalentes comparten pesos
 $\Rightarrow O(N)$.
- ❸ **Propiedades teóricas:** Se conservan algunas propiedades de aproximación universal con menos parámetros.

- 1 Carga y preprocesamiento (normalización, binarización).
- 2 Mapeo p-ádico de la imagen a un árbol jerárquico.
- 3 Configuración de la pRBM (organización jerárquica + pesos compartidos).
- 4 Entrenamiento mediante Divergencia Contrastiva.
- 5 Evaluación frente a una RBM convencional.

Métricas de evaluación

- 1 Número de parámetros entrenables.
- 2 Error de reconstrucción (MSE).
- 3 Tiempo de entrenamiento.
- 4 Uso de memoria.

Métricas obtenidas

Métricas de evaluación vs. radio de soporte p-ádico (sección 3.3)




Figura: Métricas obtenidas respecto a radio de soporte p-ádico

Convergencia: pseudo-verosimilitud

- La pseudo-verosimilitud se aproxima a 0 conforme avanza el entrenamiento, como predice la teoría.




Figura: Convergencia de la pRBM según la pseudo verosimilitud

Reconstrucción de dígitos MNIST

- Comparación visual: dígito original, reconstrucción pRBM, reconstrucción RBM.
- A simple vista las reconstrucciones son competitivas; el MSE favorece ligeramente a la RBM.



Reconstrucción de
pRBM vs RBM con
radio de soporte 1.

Reconstrucción de
pRBM vs RBM con
radio de soporte 4.

- Pendiente: implementación completamente p-ádica (actualmente árbol n-ario genérico).
- Extensión a Deep Boltzmann Machines (múltiples capas ocultas).
- Falta demostración formal rigurosa de la reducción $O(N^2) \rightarrow O(N)$.
- Pregunta abierta: ¿se preserva la propiedad de aproximador universal (Le Roux & Bengio) en el caso p-ádico?

- Se revisó la estructura matemática y computacional de las pRBM.
- Bajo ciertas condiciones, pRBM y RBM son equivalentes en desempeño de error.
- El uso de distintos cuerpos numéricos abre nuevas herramientas matemáticas/físicas para el aprendizaje de máquina.

- ① W. A. Zúñiga-Galindo, "p-adic Statistical Field Theory and Deep Belief Networks," *Physica A*, vol. 612, 2023.
- ② W. A. Zúñiga-Galindo, C. He, B. A. Zambrano-Luna, "p-Adic Statistical Field Theory and Convolutional Deep Boltzmann Machines," *PTEP*, vol. 2023, no. 6, 2023.
- ③ N. Le Roux, Y. Bengio, "Representational power of RBMs and DBNs," *Neural Computation*, vol. 20, no. 6, 2008.