

Teoría estadística de campos p-ádicos y máquinas de Boltzmann convolucionales

David Felipe Angel Herrera* and Cristian Leonardo Castañeda Olarte**

Departamento de Matemáticas - Universidad Nacional de Colombia
Bogotá, Colombia

Julio 28, 2026

RESUMEN

Las Máquinas de Boltzmann profundas constituyen una familia de modelos generativos capaces de aprender distribuciones de probabilidad complejas. Sin embargo, su aplicación a problemas de alta dimensionalidad se ve limitada por el elevado número de parámetros requerido por sus arquitecturas densamente conectadas. Recientemente, se ha propuesto una correspondencia entre las Teorías de Campo Estadístico (SFT) y las redes neuronales, donde la geometría del espacio subyacente determina la estructura y eficiencia del modelo. En particular, la formulación sobre espacios p-ádicos permite definir una arquitectura jerárquica basada en árboles ultramétricos que reduce el crecimiento del número de parámetros de un orden cuadrático a uno lineal mediante un mecanismo de compartición de pesos. En este trabajo se implementa una versión simplificada de la *p-adic Convolutional Deep Boltzmann Machine* (pCDBM) propuesta en la literatura y se evalúa experimentalmente utilizando el conjunto de datos MNIST. Finalmente, se compara su desempeño con una Restricted Boltzmann Machine (RBM) convencional, analizando y comparando la reducción de parámetros, el error de reconstrucción y el costo computacional de ambas arquitecturas.

1. Introducción

El desarrollo de arquitecturas de aprendizaje profundo ha permitido avances significativos en visión artificial y procesamiento de lenguaje. Sin embargo, la dependencia de estructuras densamente conectadas conlleva a un incremento significativo en el número de parámetros, limitada por el crecimiento cuadrático $O(N^2)$ en modelos tales como las Máquinas de Boltzmann. Recientemente, se ha propuesto una correspondencia entre las Teorías de Campo Estadístico (SFT) y las redes neuronales, sugiriendo que la geometría del espacio subyacente puede utilizarse para diseñar arquitecturas neuronales con propiedades computacionales favorables.

En este trabajo, estudiamos cómo la sustitución del espacio euclideo tradicional por el cuerpo de los números p-ádicos ($\mathbb{Q}_p$) induce una estructura jerárquica natural ideal para modelos generativos. Debido a sus propiedades ultramétricas, los números p-ádicos, y en particular los enteros p-ádicos, se organizan en estructura de árbol, lo que permite definir una convolución p-ádica que reduce la complejidad de los parámetros a un orden lineal $O(N)$. El objetivo de este proyecto es implementar una versión simplificada de esta arquitectura y explorar experimentalmente su capacidad para aprender representaciones jerárquicas utilizando un número significativamente menor de parámetros requeridos por modelos convencionales.

2. Marco Teórico

El fundamento de este proyecto yace en la conjunción entre la física estadística de campos y las arquitecturas generativas de aprendizaje profundo. En particular, los artículos estudiados muestran cómo una teoría de campo definida sobre un espacio p-ádico puede dar lugar a una nueva familia de Máquinas de Boltzmann con estructura jerárquica y un número reducido de

parámetros. A continuación, se presentan los conceptos necesarios para comprender esta propuesta.

2.1. Máquinas de Boltzmann (BM)

Las Máquinas de Boltzmann BM (*Boltzmann Machines*) son modelos generativos probabilísticos inspirados en la mecánica estadística, diseñados para aprender distribuciones de probabilidad a partir de los datos. Están formadas por un conjunto de neuronas binarias interconectadas, cuyo comportamiento se describe mediante un funcional de energía. Durante el entrenamiento, la red ajusta sus parámetros para asignar menor energía a las configuraciones que representan adecuadamente los datos observados y mayor energía a las configuraciones menos probables, puesto que se busca siempre encontrar un estado donde la energía alcance un mínimo óptimo. Aunque las BM poseen una gran capacidad de representación, su entrenamiento resulta computacionalmente costoso debido a las conexiones entre todas las neuronas. Esta limitación motivó el desarrollo de arquitecturas más eficientes, como las *Restricted Boltzmann Machines* (RBM), que restringen la conectividad de la red para facilitar el aprendizaje.

2.2. Restricted Boltzmann Machines (RBM)

Las *Restricted Boltzmann Machines* (RBM) constituyen una simplificación de las Máquinas de Boltzmann convencionales. Su principal característica es que restringen las conexiones entre neuronas, permitiendo únicamente interacciones entre la capa visible (v) y la capa oculta (h), sin conexiones dentro de una misma capa. Esta restricción reduce considerablemente la complejidad del entrenamiento y hace posible el uso de algoritmos eficientes como la divergencia contrastiva.

No obstante, cada unidad visible continúa conectándose con todas las unidades ocultas mediante una matriz de pesos densa. Como consecuencia, el número de parámetros crece aproximadamente de forma cuadrática ($O(N^2)$), lo que limita la escalabilidad del modelo cuando se trabaja con datos de alta dimensión y

* E-mail: dangelh@unal.edu.co

** E-mail: crcastanedao@unal.edu.co

constituye una de las principales motivaciones para el desarrollo de arquitecturas más eficientes.

2.3. Convolutional Deep Boltzmann Machines (CDBM)

Las *Convolutional Deep Boltzmann Machines* (CDBM) incorporan una estructura convolucional que permite compartir parámetros entre distintas regiones de la entrada, reduciendo significativamente el número de pesos respecto a una *DBM Deep Boltzmann Machine* completamente conectada. La propuesta estudiada en este trabajo toma esta idea como punto de partida y la extiende al contexto de la geometría y topología p-ádica.

2.4. Correspondencia con las Teorías de Campo Estadístico (SFT)

Uno de los principales aportes de los artículos consiste en establecer una correspondencia entre las Máquinas de Boltzmann y las *Statistical Field Theories* (SFT). En este enfoque, la función de energía de la red neuronal puede interpretarse como la discretización de una teoría de campo continua definida sobre un espacio geométrico.

Esta formulación permite trasladar propiedades geométricas del espacio subyacente al diseño de arquitecturas neuronales. En particular, al modificar la geometría sobre la cual se define la teoría de campo, es posible construir modelos con diferentes propiedades computacionales y estructurales.

2.5. Geometría p-ádica y Estructura Ultramétrica

La propuesta desarrollada en los artículos consiste en definir la teoría de campo sobre el cuerpo de los números p-ádicos ($\mathbb{Q}_p$) en lugar del espacio euclideo.

Los números p-ádicos forman un espacio ultramétrico, es decir, satisfacen la desigualdad triangular fuerte. En particular para los enteros p-ádicos, los puntos no se organizan linealmente como en el espacio euclideo, sino mediante un árbol jerárquico infinito p-ario, puesto que la métrica inducida por la norma p-ádica permite organizar a los elementos con base en su descomposición en factores primos y qué tan factorizable sean los mismos respecto al número primo p. Esta estructura posee dos propiedades fundamentales:

- **Jerarquía natural:** La cercanía entre dos puntos está determinada por el ancestro común que comparten dentro del árbol, proporcionando una representación jerárquica adecuada para modelar relaciones presentes en datos complejos.
- **Discretización:** Al truncar el árbol a una profundidad finita l , la teoría de campo continua se transforma en una representación discreta y computable, sobre la cual puede implementarse una arquitectura neuronal.




Figura 1: Árbol con raíz asociado al grupo $\mathbb{Z}_2/2^3\mathbb{Z}_2$. Imagen tomada de [1]

2.6. Arquitectura de la CDBM p-ádica

La *p-adic Convolutional Deep Boltzmann Machine* (pCDBM) constituye la variante específica propuesta en los artículos que se toman como referencia y se obtiene al discretizar una teoría de campo estadístico definida sobre un espacio p-ádico. Esta arquitectura combina la organización jerárquica

inducida por la propiedad ultramétrica con una operación de convolución adaptada a dicha estructura. Sus principales características son:

1. **Convolución p-ádica:** La interacción entre neuronas se expresa mediante un núcleo de convolución que depende de la distancia entre nodos dentro del árbol p-ádico. Esto introduce una simetría de traslación propia del espacio p-ádico y evita definir un peso independiente para cada conexión, esto se realiza mediante la convolución de las funciones respecto a funciones de prueba (que son funciones localmente constantes con soporte compacto), estas están dadas a su vez gracias a la topología p-ádica.
2. **Compartición de parámetros:** Gracias a la simetría, neuronas ubicadas en posiciones equivalentes del árbol comparten los mismos pesos. Como resultado, el número de parámetros pasa de crecer aproximadamente como $O(N^2)$ a hacerlo de forma lineal ($O(N)$), reduciendo considerablemente el costo computacional.
3. **Propiedades teóricas:** Los artículos [1] y [2] demuestran que, bajo determinadas condiciones, esta arquitectura conserva propiedades de aproximación universal al tiempo que utiliza un número significativamente menor de parámetros que las arquitecturas densas convencionales.

3. Metodología

Debido a la complejidad matemática de la arquitectura original, en este proyecto se implementó una versión simplificada inspirada en la *p-adic Restricted Boltzmann Machine* (pRBM) propuesta en la literatura, la cual mantiene la propiedad de convolución. Esta implementación conserva la organización jerárquica y el mecanismo de compartición de pesos del modelo original, permitiendo evaluar experimentalmente sus principales propiedades y compararlas con una RBM convencional.

3.1. Flujo de Trabajo

El desarrollo del proyecto se organizó en cinco etapas consecutivas:

1. **Carga y preprocesamiento:** Selección, normalización y binarización del conjunto de datos.
2. **Mapeo p-ádico:** Transformación de la representación bidimensional de las imágenes en una estructura jerárquica basada en un árbol p-ádico.
3. **Configuración de la pRBM:** Construcción de la arquitectura neuronal con organización jerárquica y compartición de pesos.
4. **Entrenamiento:** Ajuste de los parámetros mediante el algoritmo de Divergencia Contrastiva.
5. **Evaluación:** Comparación del desempeño de la arquitectura propuesta frente a una RBM convencional mediante distintas métricas de rendimiento.

3.2. Implementación Técnica

La implementación experimental se realizó siguiendo las decisiones metodológicas descritas a continuación.

- **Entorno de desarrollo:** El modelo fue implementado en **Python**, utilizando la biblioteca **PyTorch** para la construcción de la red neuronal, el manejo de tensores y las operaciones de optimización.
- **Dataset:** Se empleó el conjunto de datos **MNIST**, compuesto por imágenes de dígitos manuscritos. Como etapa de preprocesamiento, las imágenes originales de 28×28 píxeles fueron binarizadas.

- **Representación jerárquica:** Cada imagen fue reorganizada siguiendo la estructura de un árbol p-ádico. Para ello, los píxeles se agruparon recursivamente en regiones espaciales, construyendo una representación jerárquica. Se seleccionó un árbol de profundidad l que varía en radio p-ádico, lo anterior empleando en el primo $p = 3$.
- **Arquitectura implementada:** Se implementó una versión simplificada de la pRBM compuesta por una única capa oculta, conservando la organización jerárquica y el mecanismo de compartición de pesos descritos en los artículos de referencia.
- **Algoritmo de aprendizaje:** El entrenamiento se realizó mediante Divergencia Contrastiva con un paso de Gibbs (CD-1). Este algoritmo aproxima el gradiente de la log-verosimilitud utilizando cadenas cortas de muestreo, permitiendo actualizar los pesos de manera eficiente.
- **Hiperparámetros:** El modelo fue entrenado durante 250 épocas, utilizando una tasa de aprendizaje 0,01, con cálculo de mini lote (minibatch size) de 16 por época y Divergencia Contrastiva con un único paso de Gibbs (CD-1).

3.3. Métricas de Evaluación

Con el fin de comparar el desempeño de la arquitectura propuesta con una RBM convencional, se evaluaron las siguientes métricas:

1. **Número de parámetros entrenables:** Conteo total de pesos libres de la red, utilizado para cuantificar la reducción obtenida mediante el mecanismo de compartición de parámetros.
2. **Error de reconstrucción:** Medido mediante el Error Cuadrático Medio (MSE) entre la imagen original y la imagen reconstruida por la red.
3. **Tiempo de entrenamiento:** Tiempo promedio requerido por época y tiempo total de entrenamiento hasta completar el número de épocas establecido.
4. **Uso de memoria:** Comparación del consumo de memoria asociado al almacenamiento de parámetros entre la pRBM y una RBM convencional.

4. Resultados

Los resultados obtenidos al entrenar la RBM y la pRBM (p-ádico Restricted Boltzmann Machine) son los siguientes respecto a las métricas establecidas:




Figura 2: Métricas obtenidas respecto a radio de soporte p-ádico

En la anterior figura se describe el desempeño de una RBM (*Restricted Boltzmann Machine*) señalada con el color rojo respecto a una pRBM (*p-ádico Restricted Boltzmann Machine*) señalada con el color azul, donde se evalúan las 4 métricas anteriormente mencionadas.

Como se evidencia en el primer gráfico, la cantidad de parámetros corresponde a lo anteriormente mencionado, en tanto que el número de parámetros entrenables correspondientes a la pRBM ronda valores uniformes respecto al radio de soporte de alrededor de $N \approx 10^3$, mientras que los correspondientes a la RBM ronda valores alrededor de $N \approx 10^6$. Este hecho resulta significativo al contrastar esta métrica con respecto a la segunda que se constituye del error de reconstrucción respecto a las imágenes originales, esta métrica se calcula a partir del MSE. En esta se evidencia que para radio p-ádico 1 y 4 los errores cometidos por la pRBM son extremadamente cercanos a los cometidos por la RBM, de tal suerte que con un número mucho menor de parámetros es posible obtener una red neuronal que es capaz de reconstruir imágenes con un desempeño óptimo.

La tercera métrica a su vez representa un hecho importante, y es que naturalmente a medida que se incrementa el radio p-ádico y por tanto la capacidad de la red, se incrementa el tiempo de entrenamiento, este hecho resulta relevante pues a nivel energético y de manejo de recursos no resulta ser óptimo, al menos para el número de muestras sobre el que se entrenó la red en este caso, el incrementar el radio p-ádico, dado que tampoco se incrementa la precisión de la misma, posiblemente por un problema de *sobreajuste* dado el tamaño de la muestra de MNIST. Es importante notar que para el radio de soporte p-ádico 1, los tiempos de ejecución son aún cercanos a los de la RBM convencional, lo cual implica que puede ser óptimo usar tal valor como referencia.

Finalmente, la cuarta métrica demuestra que en efecto el uso de memoria de la pRBM es significativamente inferior que el de una RBM clásica, lo anterior debido al número de parámetros.

Los resultados de la convergencia respecto a la pseudo-verosimilitud de la pRBM se presentan a su vez la siguiente figura:




Figura 3: Convergencia de la pRBM según la pseudo verosimilitud

Lo anterior coincide en efecto con lo presentado en la primera figura de la sección de resultados, pues los errores de reconstrucción que representan valores pequeños coinciden efectivamente con que la pseudo-verosimilitud se aproxima a cero, tal y como sugiere la teoría.

El último resultado que se presenta a continuación representa la reconstrucción que realiza la pRBM en contraste con la RBM, con respecto a algunos dígitos de MNIST:




Figura 4: Reconstrucción de pRBM vs RBM con radio de soporte 1




Figura 5: Reconstrucción de pRBM vs RBM con radio de soporte 4

A la izquierda de cada figura se presenta el dígito originalmente dado por parte de la validación del entrenamiento, la columna central presenta la reconstrucción realizada por la pRBM y la columna de la derecha la reconstrucción de la RBM. Como se evidencia, para ambos radios de soporte las reconstrucciones son muy cercanas a las realizadas por la RBM y a simple vista en algunos casos es mejor, sin embargo, el MSE de la primera figura de la sección evidencia que en efecto la RBM sigue aproximando de mejor manera los datos de MNIST.

5. Discusión

Algunos resultados que aún quedan pendientes por verificar se remiten a aspectos teóricos y de implementación relacionados con la estructura p-ádica de la red. Un aspecto relevante que queda por desarrollar en cuanto a la implementación es la estructura de árbol que navega la red, pues en la implementación actual se sigue preservando una estructura referente a un árbol n-ario sin las bondades y defectos que constituye el trabajar con árboles p-ádicos propiamente, pues este hecho podría impactar en el rendimiento de la red e incrementar o decrementar los errores que comete, por tanto es de interés de los autores explorar a mayor profundidad una implementación completamente p-ádica de la pRBM.

Otro tema de interés a su vez se relaciona con una implementación de una red neuronal profunda para obtener una máquina de Boltzmann Profunda (DBM), pues en los artículos referenciados [1] y principalmente en el [2] se realiza un estudio de las mismas desde el punto de vista del modelo físico más no del modelo computacional de forma directa, este artículo se limita a la implementación de una red con una sola capa profunda y a la descripción teórica de un modelo más general.

En cuanto al aspecto teórico, aún resta desarrollar la demostración formal de la reducción de orden de $O(N^2)$ a $O(N)$, pues esta reducción es descrita por los autores en [2] a partir de heurísticas sin una demostración formal del caso general. Adicionalmente existe un artículo relevante de Le Roux y Bengio [3]

el cual describe las bondades del uso de RBM y su forma más general las Redes de Creencia Profunda (DBN) como aproximadores universales, la demostración naturalmente se realiza sobre una estructura real por lo que resulta de interés de los autores comprobar si la misma es válida en el caso p-ádico de este tipo de redes, pues no necesariamente las pRBM tendrán tal propiedad al realizar la generalización.

6. Conclusiones

En el presente trabajo inicialmente se revisó la estructura matemática y computacional de nuestro objeto de estudio, las Máquinas de Boltzmann Restringidas Convolucionales P-ádicas (pCRBM). El objetivo fue comprender su funcionamiento y las ventajas que ofrecen con respecto al modelo real. En este sentido, se llevo a cabo la revisión, adaptación y optimización de los códigos provenientes del artículo [2], los cuales fueron facilitados por sus autores.

Al realizar los experimentos con el conjunto de datos MNIST, se contrastó que en efecto existen diferencias en el desempeño computacional de ambos modelos. A criterio de los autores, esto se debe a múltiples optimizaciones que han recibido las librerías empleadas para el modelo de la RBM convencionales.

Gracias a las pruebas realizadas, fue posible comprobar que bajo determinadas condiciones y al evaluar sus medidas de error, ambas arquitecturas resultan equivalentes en cuanto a desempeño. Este hecho demuestra que el uso de distintos cuerpos puede resultar beneficioso para el estudio del aprendizaje de máquina, pues estos enfoques distintos abren la posibilidad de estudiar las mismas con técnicas matemáticas, estadísticas y físicas distintas a las tradicionales, lo cual da lugar a un marco en el estudio novedoso de la inteligencia artificial que podría brindar luces sobre su funcionalidad y permitir un análisis más riguroso y fundamentado.

7. Apéndice

A continuación establecemos una tabla con los valores de los hiperparámetros empleados en el entrenamiento con el fin de permitir su repetición:

Hiperparámetro	Valor	Qué controla
p	3	Base del sistema p -ádico. Define el árbol p -ario sobre el que se construye la representación de la imagen.
l	3	Nivel/profundidad del árbol p -ádico. El tamaño de la imagen (tras <code>resize</code> en <code>TreeGen.img_tree_array</code>) es $N = p^l$.
<code>n_features</code>	729	Número de unidades visibles. Debe cumplir $n_features = p^{2l}$.
<code>h_features</code>	2187	Número de unidades ocultas.
<code>patch_per_image</code>	16	Aumento de datos por parches.
<code>patch_size</code>	64	Tamaño del parche extraído.
<code>n_iterations</code>	250	Número de épocas de entrenamiento (sweeps completos sobre el dataset).
<code>save_models</code>	True	Si se guardan checkpoints intermedios.
k	1	Orden de la divergencia contrastiva (CD- k): número de pasos de Gibbs sampling dentro de <code>_fit</code> para generar la muestra negativa (v_{neg}).
<code>n_components</code>	4096	Número de unidades visibles — debe coincidir con <code>args.n_features</code> .
<code>h_components</code>	4096	Número real de unidades ocultas (coincide con <code>args.h_features</code>). Determina el tamaño de <code>intercept_hidden_</code> .
<code>learning_rate</code>	0.01	Tasa de aprendizaje para las actualizaciones SGD-like en <code>fit</code> .
<code>batch_size</code>	16	Tamaño del minibatch.
<code>n_iter</code>	10	Número de iteraciones de entrenamiento a nivel de la clase (distinto de <code>args.n_iterations</code> ; en la práctica los scripts pasan explícitamente <code>n_iter=n_iterations</code>).
<code>verbose</code>	0	Nivel de verbosidad; si es <code>truthy</code> , calcula y grafica <code>pl_history</code> (pseudo-verosimilitud).
<code>random_state</code>	None	Semilla para reproducibilidad.
<code>rad_supp</code>	0	Hiperparámetro de control de capacidad del modelo p -ádico. Define el radio de soporte: de los <code>n_components</code> pesos del kernel circulante <code>components</code> , solo los primeros p^{rad_supp} se inicializan con valores aleatorios; el resto se rellena con ceros vía <code>components_.resize(n_components)</code> .

Referencias

[1] W. A. Zúñiga-Galindo, “ p -adic Statistical Field Theory and Deep Belief Networks,” *Physica A: Statistical Mechanics and its Applications*, vol. 612, Art. no. 128492, 2023, doi: 10.1016/j.physa.2023.128492.

[2] W. A. Zúñiga-Galindo, C. He, and B. A. Zambrano-Luna, “ p -Adic Statistical Field Theory and Convolutional Deep Boltzmann Machines,” *Progress of Theoretical and Experimental Physics*, vol. 2023, no. 6, Art. no. 063A01, Jun. 2023, doi: 10.1093/ptep/ptad061.

[3] N. Le Roux and Y. Bengio, “Representational power of restricted Boltzmann machines and deep belief networks,” *Neural Computation*, vol. 20, no. 6, pp. 1631–1649, 2008.

340